



JOURNAL OF IMAGE AND GRAPHICS

主办: 中国科学院空天信息创新研究院
中国图象图形学学会
北京应用物理与计算数学研究所

中国图象图形学报

2021
01
VOL.26

ISSN1006-8961
CN11-3758/TB





第26卷第1期 (总第297期)

2021年1月16日

中国精品科技期刊
中国国际影响力优秀学术期刊
中国科技核心期刊
中文核心期刊

版权声明

凡向《中国图象图形学报》投稿, 均视为同意在本刊网站及CNKI等全文数据库出版, 所刊载论文已获得著作权人的授权。本刊所有图片均为非商业目的使用, 所有内容, 未经许可, 不得转载或以其他方式使用。

Copyright

All rights reserved by Journal of Image and Graphics, Institute of Remote Sensing and Digital Earth, CAS. The content (including but not limited text, photo, etc) published in this journal is for non-commercial use.

主管单位 中国科学院
主办单位 中国科学院空天信息创新研究院
中国图象图形学学会
北京应用物理与计算数学研究所

主 编 吴一戎
编辑出版 《中国图象图形学报》编辑出版委员会
通信地址 北京市海淀区北四环西路19号
邮 编 100190
电子信箱 jig@radi.ac.cn
电 话 010-58887035
网 址 www.cjig.cn

广告发布登记号 京朝工商广登字20170218号
总 发 行 北京报刊发行局
订 购 全国各地邮局
海外发行 中国国际图书贸易集团有限公司
(邮政信箱: 北京399信箱 邮编: 100048)
印刷装订 北京科信印刷有限公司

Journal of Image and Graphics

Title inscription: Song Jian

Monthly, Started in 1996

Superintended by Chinese Academy of Sciences
Sponsored by Aerospace Information Research Institute, CAS
China Society of Image and Graphics
Institute of Applied Physics and Computational Mathematics

Editor-in-Chief Wu Yirong
Editor, Publisher Editorial and Publishing Board of Journal of Image and Graphics
Address No. 19, North 4th Ring Road West, Haidian District, Beijing, P. R. China
Zip code 100190
E-mail jig@radi.ac.cn
Telephone 010-58887035
Website www.cjig.cn


Distributed by Beijing Bureau for Distribution of Newspapers and Journals
Domestic All Local Post Offices in China
Overseas China International Book Trading Corporation
(P.O.Box 399, Beijing 100048, P.R.China)
Printed by Beijing Kexin Printing Co., Ltd.

CN 11-3758/TB
ISSN 1006-8961
CODEN ZTTXFZ

国外发行代号 M1406
国内邮发代号 82-831
国内定价 60.00元



面向智能驾驶的平行视觉感知：基本概念、框架与应用
(第0067页)



Edge-guided GAN: 边界信息引导的深度图像修复
(第0186页)



利用边缘计算的多车协同激光雷达SLAM(第0218页)

序言	王飞跃, 张云泉 I
编者按	II

综述

面向智能驾驶测试的仿真场景构建技术综述	
任秉韬, 邓伟文, 白雪松, 李江坤, 纵瑞雪, 朱冰, 丁娟	0001
自动驾驶软件测试技术研究综述	
冯洋, 夏志龙, 郭安, 陈振宇	0013
强化学习的自动驾驶控制技术研究进展	
潘峰, 鲍泓	0028
自动驾驶地图的数据标准比较研究	
詹骄, 郭迟, 雷婷婷, 屈宜琪, 吴杭彬, 刘经南	0036
视觉感知的端到端自动驾驶运动规划综述	
刘旖菲, 胡学敏, 陈国文, 刘士豪, 陈龙	0049

平行驾驶

面向智能驾驶的平行视觉感知：基本概念、框架与应用	
李轩, 王飞跃	0067
平行视觉的基本框架与关键算法	
张慧, 李轩, 王飞跃	0082

目标检测与跟踪

自动驾驶场景的尺度感知实时行人检测	
徐歆恺, 马岩, 钱旭, 张龔	0093
实时视觉目标跟踪与视频对象分割多任务框架	
李瀚, 刘坤华, 刘嘉杰, 张晓晔	0101
提升预测框定位稳定性的视频目标检测	
郝腾龙, 李熙莹	0113
道路结构特征下的车道线智能检测	
张翔, 唐小林, 黄岩军	0123
适用全速域大曲率路径的自动驾驶跟踪算法	
张龔, 郑颖, 鲍泓	0135
伪3D卷积神经网络与注意力机制结合的疲劳驾驶检测	
庄员, 戚湧	0143
基于眼部自商图—梯度图共生矩阵的疲劳驾驶检测	
潘剑凯, 柳政卿, 王秋成	0154

自动驾驶场景感知与仿真

结合局部平面参数预测的无监督单目图像深度估计	
周大可, 田径, 杨欣	0165
深度纯追随的拟人化无人驾驶转向控制模型	
单云霄, 黄润辉, 何泽, 龚志豪, 景民, 邹雪松	0176
Edge-guided GAN: 边界信息引导的深度图像修复	
刘坤华, 王雪辉, 谢玉婷, 胡坚耀	0186
引入概率分布的深度神经网络贪婪剪枝	
胡骏, 黄启鹏, 刘嘉昕, 刘威, 袁淮, 赵宏	0198

高精地图构建与SLAM


开放道路中匹配高精度地图的在线相机外参标定	
廖文龙, 赵华卿, 严骏驰	0208
利用边缘计算的多车协同激光雷达SLAM	
崔明月, 钟仕鹏, 刘思瑶, 李博洋, 吴成昊, 黄凯	0218

CONTENTS

JOURNAL OF IMAGE AND GRAPHICS



Parallel visual perception for intelligent driving: basic concept, framework and application (P0067)



Edge-guided GAN: a depth image inpainting approach guided by edge information (P0186)



Cooperative LiDAR SLAM for multi-vehicles based on edge computing (P0218)

Review

- Technologies of virtual scenario construction for intelligent driving testing
Ren Bingtao, Deng Weiwen, Bai Xuesong, Li Jiangkun, Zong Ruixue, Zhu Bing, Ding Juan 0001
- Survey of testing techniques of autonomous driving software
Feng Yang, Xia Zhilong, Guo An, Chen Zhenyu 0013
- Research progress of automatic driving control technology based on reinforcement learning
Pan Feng, Bao Hong 0028
- Comparative study on data standards of autonomous driving map
Zhan Jiao, Guo Chi, Lei Tingting, Qu Yiqi, Wu Hangbin, Liu Jingnan 0036
- Review of end-to-end motion planning for autonomous driving with visual perception
Liu Yifei, Hu Xuemin, Chen Guowen, Liu Shihao, Chen Long 0049

Parallel Driving

- Parallel visual perception for intelligent driving: basic concept, framework and application
Li Xuan, Wang Feiyue 0067
- The basic framework and key algorithms of parallel vision
Zhang Hui, Li Xuan, Wang Feiyue 0082

Object Detection and Tracking

- Scale-aware EfficientDet: real-time pedestrian detection algorithm for automated driving
Xu Xinkai, Ma Yan, Qian Xu, Zhang Yan 0093
- Multitask framework for video object tracking and segmentation combined with multi-scale inter-frame information
Li Han, Liu Kunhua, Liu Jiajie, Zhang Xiaoye 0101
- Video object detection method for improving the stability of bounding box
Hao Tenglong, Li Xiying 0113
- Intelligent detection of lane based on road structure characteristics
Zhang Xiang, Tang Xiaolin, Huang Yanjun 0123
- Autonomous vehicle tracking algorithm for high curvature path in full speed range
Zhang Yan, Zheng Ying, Bao Hong 0135
- Driving fatigue detection based on pseudo 3D convolutional neural network and attention mechanisms
Zhuang Yuan, Qi Yong 0143
- Fatigue driving detection based on ocular self-quotient image and gradient image co-occurrence matrix
Pan Jiankai, Liu Zhengqing, Wang Qiucheng 0154

Scene Perception and Simulation of Autonomous Driving

- Unsupervised monocular image depth estimation based on the prediction of local plane parameters
Zhou Dake, Tian Jing, Yang Xin 0165
- Human-like steering model for autonomous driving based on deep pure pursuit method
Shan Yunxiao, Huang Runhui, He Ze, Gong Zhihao, Jing Min, Zou Xuesong 0176
- Edge-guided GAN: a depth image inpainting approach guided by edge information
Liu Kunhua, Wang Xuehui, Xie Yuting, Hu Jianyao 0186
- Greedy pruning of deep neural networks fused with probability distribution
Hu Jun, Huang Qipeng, Liu Jiaxin, Liu Wei, Yuan Huai, Zhao Hong 0198

High-Definition Map Construction and SLAM

- Online extrinsic camera calibration based on high-definition map matching on public roadway
Liao Wenlong, Zhao Huaqing, Yan Junchi 0208
- Cooperative LiDAR SLAM for multi-vehicles based on edge computing
Cui Mingyue, Zhong Shipeng, Liu Siyao, Li Boyang, Wu Chenghao, Huang Kai 0218

中图法分类号: TP399 文献标识码: A 文章编号: 1006-8961(2021)01-0218-11

论文引用格式: Cui M Y, Zhong S P, Liu S Y, Li B Y, Wu C H and Huang K. 2021. Cooperative LiDAR SLAM for multi-vehicles based on edge computing. Journal of Image and Graphics, 26(01): 0218-0228 [崔明月, 钟仕鹏, 刘思瑶, 李博洋, 吴成昊, 黄凯. 2021. 利用边缘计算的多车协同激光雷达 SLAM. 中国图象图形学报, 26(01): 0218-0228] [DOI: 10.11834/jig.200441]

利用边缘计算的多车协同激光雷达 SLAM

崔明月¹, 钟仕鹏¹, 刘思瑶², 李博洋¹, 吴成昊², 黄凯¹

1. 中山大学数据科学与计算机学院, 广州 510000; 2. 中山大学智能工程学院, 深圳 518000

摘要: 目的 激光雷达实时定位与建图(simultaneous localization and mapping, SLAM)是智能机器人领域的重要组成部分,通过对周边环境的3维建模,可以实现无人驾驶车辆的自主定位和精准导航。针对目前单个车辆激光雷达建图周期长、算力需求大的现状,提出了基于边缘计算的多车协同建图方法,能够有效地负载均衡,在保证单个车辆精准定位的同时,增加多个车辆之间的地图重用性。**方法** 构建基于阈值的卸载函数,论证边缘计算下的多车卸载决策属于势博弈问题,设计实现基于边缘计算的势博弈卸载算法,在模型具有纳什均衡的基础上实现任务调度,引入 α -Nash 最佳响应动态加速算法收敛,并采用由粗到细的点云匹配方法提高地图匹配性能,实现车辆的精准定位。最后,基于地图的相对可信度,高效地合并基站覆盖范围内的多个车辆的建图数据。**结果** 实验表明,基于博弈论的调度方法在保证定位可靠性的前提下,能够有效地实现多车协同 SLAM,且多车协同的定位与建图结果与使用载波相位差分技术(real-time kinematic, RTK)的高精度差分全球定位系统(differential global positioning system, DGPS)结果足够接近,相比于单车建图而言,横向定位和纵向定位的平均精度分别提高了 6.0 倍和 3.9 倍。**结论** 本文方法解决了基于边缘计算的多车协同激光雷达 SLAM 问题,借助边缘服务器的计算资源,无人驾驶车辆可以有效地减少本地资源需求和定位延迟。该方法通过各个车辆之间的资源博弈,最终实现纳什均衡。实现基于边缘计算的激光雷达定位服务,且高效地完成多车之间的地图合并,仿真和真实环境中的实验表明了方法的有效性。**关键词:** 边缘计算;激光雷达实时定位与构图(SLAM);任务卸载;多车协同;无人驾驶

Cooperative LiDAR SLAM for multi-vehicles based on edge computing

Cui Mingyue¹, Zhong Shipeng¹, Liu Siyao², Li Boyang¹, Wu Chenghao², Huang Kai¹

1. School of Data and Computer Science, Sun Yat-sen University, Guangzhou 510000, China;

2. School of Intelligent Systems Engineering, Sun Yat-sen University, Shenzhen 518000, China

Abstract: **Objective** LiDAR simultaneous localization and mapping (SLAM) is an important component of the field of intelligent robotics. The robot should be able to perceive the information of the surrounding environment and accurately locate its own position, which is also the premise for the robot to autonomously navigate. Building the entire map requires the single vehicle to drive all over the whole area, which makes the mapping periods longer. In addition, more data require more computing power for onboard units. To solve the above problems, a cooperative LiDAR SLAM for multi-vehicles based on edge computing method is proposed. This method can make the load balance by offloading tasks to the edge server. Aside from ensuring accurate localization of the single vehicle, it can also increase the reusability of the mapping results for multi-vehicles. This study models the computation offloading decision-making problem among multi-vehicles as a task offloading

收稿日期: 2020-08-01; 修回日期: 2020-10-19; 预印本日期: 2020-10-26

基金项目: 国家重点研发计划项目(2018YFB1802400); 广州市科技计划项目(202007050004)

Supported by: National Key Research and Development Program of China(2018YFB1802405)

game. It designs the offloading algorithm based on the potential game to compute the task scheduling sequence. The concept of relative confidence is introduced to reduce the odometer error in the process of mapping as much as possible, which also makes our merged maps of multi-vehicles more accurate. **Method** First, this study constructs a threshold-based offloading function that includes latency constraint and signal quality constraint. Then, this study proves that the minimum latency problem of multi-vehicles is a potential game. The potential game always reaches the Nash equilibrium and has limited improved properties. Therefore, the relevant strategy based on the potential game is designed for offloading tasks. With the characteristics of the Nash equilibrium, our algorithm ensures that vehicles in equilibrium can obtain mutually satisfactory solutions. This study introduces the concept of α -Nash dynamics to speed up the convergence of the algorithm. Then, a coarse-to-fine point cloud matching scheme is used to realize the map matching. During the coarse matching phase, the point cloud data of different vehicles are initially matched. This study uses the fast point feature histogram algorithm to extract key points and descriptors from the point cloud and the distance between the point pair within the spherical neighborhood of the key point. Then, the random sample consensus (RANSAC) method is used to estimate the point-to-point correspondences between the key points, which can obtain the initial matrix rotation and translation matrix that describes the rough relative transformation of two maps. In the fine matching phase, the iterative closest-point algorithm is used to further optimize the matching results and increase accuracy. On the basis of this method, matching two-frame point clouds can converge faster and achieve a better matching result. Finally, local LiDAR maps are merged based on relative confidence. The node with the lowest weight is selected, then the node set connected with the node is sorted according to the relative confidence and the size of the overlapping area. Finally, the map is merged according to the sorted order, and the above steps are repeated until all nodes are traversed. **Result** To verify the effectiveness of this study, we conducted simulation and real-world experiments. In the simulation experiment, α is set to different values, and experiments are conducted with different numbers of vehicles. This study takes the average number of time slots and the average system-wide overhead as two important performance metrics, which indicate the convergence speed of the algorithm and the efficiency of reducing system overhead, respectively. Results show that as α decreases, the convergence speed increases, while the efficiency of reducing the system overhead decreases. To balance the two performance metrics mentioned above, the system sets the parameter α to 0.8. Results also show that under the same parameter, the average number of time slots and the average system-wide overhead increase almost linearly as the number of vehicles increases. This finding shows that our algorithm adapts well with different sizes of users. In the real-world scene, a 1.49 km campus road is chosen as the test section, including turning, going straight, and changing lanes. Three base stations and four autonomous vehicles with identical hardware configurations are deployed in the test environment. The test area is divided into three parts with the base station as the center because of the limitation of the actual number of vehicles. Three to four vehicles are presented in each area to simulate the effect of mapping results for nine vehicles. The experiment result shows that the trajectory of the cooperative mapping are closely matched with that of real-time kinematic, while the deviation for single-vehicle mapping is much larger. In addition, compared with single-vehicle mapping, the average accuracy of latitude and longitude localization for cooperative mapping is improved about 6.0 and 3.9 times, respectively. In the worst case, the accuracy improves about 1.7 times in latitude and 1.6 times in longitude. **Conclusion** This paper proposes an approach to offloading SLAM tasks based on edge computing in the multi-vehicle scenario. On the basis of edge computing, autonomous vehicles can effectively reduce local computing power and the latency of localization. This method achieves Nash equilibrium by means of resource games among several vehicles. While each vehicle realizes its accurate localization, it collaborates with other vehicles to complete the overall map construction. Simulation and experimental deployment in the real environment demonstrate the effectiveness of our method. We believe that the cooperative LiDAR SLAM for multi-vehicles based on edge computing can effectively increase the quality of service for autonomous driving.

Key words: edge computing; simultaneous localization and mapping (SLAM); task offloading; multi-vehicle collaboration; autonomous driving


0 引言

无人驾驶需要对周边环境进行3维建模,构建高精度地图用于自主定位、轨迹估计、路径规划和车辆控制等。由于激光雷达可以提供低误差且高频率的点云数据,在自动驾驶车辆部署激光雷达传感器已经变得非常普遍(Li等,2018)。典型的SLAM(simultaneous localization and mapping)地图构建需要单独覆盖整个建图区域,这往往带来较长的构建周期和较大的计算资源需求。此外,激光里程计也会随着距离增加而产生累积误差。

一种常见的解决方式是在多辆无人驾驶车上部署SLAM算法(Zhe等,2018)。更具体地说,在多车场景中,每辆车只需要探索其感兴趣的区域,通过与邻近车辆交换地图信息来协同构建环境地图,从而使每辆车获得更多的地图信息。如图1所示,相比于单车而言,多车建图可以缩小里程计里程误差。然而,车辆只能与邻近车辆进行数据交换,车辆之间的相对坐标转换也是未知的。如何以一致的方式合并所有的局部地图,这需要在协同车辆之间建立一个共同的参考系即通过中心节点对每辆车点云数据的特征信息进行配准和坐标变换,从而实现整体3维地图构建。



(a) 现实场景



(b) 单车SLAM

(c) 多车协同SLAM

图1 建图结果对比

Fig. 1 The comparison of mapping results

((a) real scene; (b) single SLAM; (c) cooperative SLAM)

基于边缘计算构建具有中心节点的多车协同SLAM系统并非易事。首先,很难有效地匹配和合并重叠的区域。尽管GPS信息缩小了地图的配准范围,但对多辆车的历史点云数据进行精确匹配仍不现实,这往往需要花费极大的算力。其次,无人驾驶车辆如何进行工作负载卸载以保证自身的精准定位,同时在边缘服务器算力有限的情况下,如何满足多辆车的卸载需求也是需解决的问题之一。最后,边缘服务器还需要合并多车建图数据,构建出完整的3维全局地图。

计算卸载调度问题的目标函数往往是非凸函数,通常的做法是使用拉格朗日松弛法来处理约束条件(Yang等,2017),或者使用一些特定的启发式算法来找到接近最优解。常用的启发式搜索算法有贪婪算法(Cui等,2017;Moubayed等,2020)、遗传算法(Deng等,2015)和粒子群算法(Rodrigues等,2018)等。这类算法通过搜索解空间来接近最优解,不同情况下的相关参数设定要求相对较高,并且合适的迭代次数无法确定,这将造成过多的计算时间和能源消耗。Wei等人(2019)使用强化学习来获得次优解或最优解。但随着问题复杂程度的增加,解空间不断扩大,仅使用Q-learning带来的计算和存储的开销将难以接受。因此,基于深度强化学习的方法(Min等,2019;Liu等,2019)被提出,以用来降低求解空间的维度。深度强化学习除了将Q-learning和神经网络结合(Chen等,2019;Zhang等,2019)来逼近值函数求解外,还可以通过异步优势actor-critic算法(asynchronous advantage actor critic, A3C)(Qi等,2019)在高维度和连续动作空间中获得更高的效率。但深度强化学习需要训练的参数数量庞大,对训练样本的数量和分布情况要求高,训练时间长,且方法的复杂度高。为了减少预设参数的数量,降低方法的复杂度,一些研究人员将问题转换为用户间的博弈来求解次优解(Yang等,2018;Wang等,2020),但此类方法随着问题规模的扩大,求解时间往往较长,无法满足车辆的低延迟要求。

基于博弈论求解任务调度问题(Chen等,2016)的启发,本文提出了一种基于边缘计算的协同激光雷达SLAM方法。将调度问题建模为策略博弈问题,并证明此问题属于势博弈(Monderer和Shapley,1996)问题。根据势博弈有限的改进特性,设计了快速收敛的多无人驾驶车辆卸载算法。此外,基于

相对可信度,计算各个车辆的地图合并序列,可以高效地匹配且合并多个车辆的建图数据。实验结果表明,该方法可以有效地实现点云匹配和地图合并,缩短响应时间,获得准确的定位结果。

1 激光雷达协同 SLAM

1.1 系统概述

基于边缘计算的多车协同 SLAM 系统框架结构如图2所示。首先,处于未知环境的无人驾驶车辆会独立进行定位与建图,并通过基站(base station, BS)与边缘服务器相连,进行计算卸载以减少本地负载。此外,点云地图和GPS等数据也被转换到BS坐标下存储到边缘服务器中。然后,系统利用车辆的GPS信息判断车辆之间是否存在重叠区域,存在则进行车辆间的地图匹配,否则根据GPS信息拼接地图。最后,系统根据地图匹配结果合并各无人驾驶车辆的局部地图。在运行时,系统会重复这个过程,直到它绘制出BS覆盖的完整地图。




图2 系统框架

Fig. 2 System framework

1.2 单车建图

本文使用的单车SLAM是基于Zhang和Singh(2014)提出的激光雷达里程计与建图(laser dometry and mapping, LOAM)算法,其不需要使用额外的高成本惯性测量单元(inertial measurement unit, IMU)就可以提供足够的定位精确度。算法流程如图3所示,主要有4个部分:特征提取、里程估计、建图和定位。算法从激光雷达中收集原始数据作为输入。然后根据数据的空间信息进行分类,并提取平面特征和角特征。接下来,里程估计需要分析连续两帧激光雷达点云的特征,并使用非线性最小二乘算法估计两者之间的坐标转换关系。再利用上述坐标转换关系估计车辆位姿,获得粗略的定位结果。在建图

部分,算法通过累积点云帧的方式将点云映射到全局坐标系,得到局部区域地图,并再次使用非线性最小二乘算法估计车辆位姿,获得精确的定位结果。




图3 单车建图流程图

Fig. 3 The single mapping pipeline

1.3 地图匹配

地图匹配的关键是准确匹配多辆车的局部地图重叠区域,并找出参考帧的相对变换。给定两帧点云作为输入,使用匹配算法(Rusinkiewicz和Levoy, 2002; Biber和Strasser, 2003)可以找出最优的 4×4 旋转平移矩阵(rotation and translation, RT),使得点云中相应点之间的距离最小化

$$T_{RT} = \begin{bmatrix} R_{3 \times 3} & T_{3 \times 1} \\ 0_{1 \times 3} & 1 \end{bmatrix} \quad (1)$$

式中, R 表示旋转矩阵, T 表示平移矩阵。随后使用RT矩阵将地图转换到同一坐标下完成地图合并。

$$M_2 = T_{RT} \times M_1 \quad (2)$$

式中, M_2 和 M_1 为各自参考系中的点坐标。

系统中的匹配节点订阅了每辆车的位姿、地图、GPS信息和以车辆ID标识的点云帧等信息,并将位姿和建图结果等转换到BS的全局坐标下。然后,各车辆的局部地图通过点云匹配算法计算RT矩阵进行地图合并。

在进行点云匹配时,匹配节点首先确定是否是第一辆无人驾驶车辆。如果是新车辆,则使用其GPS信息生成RT矩阵并存储;否则,系统将使用GPS信息搜索当前全局地图来确定局部地图是否已经存储。系统将进一步检查匹配车辆的RT矩阵列表,如果不存在两者通过匹配算法生成的RT矩阵,系统使用点云匹配算法,如迭代最近点(iterative closest point, ICP)或正态分布变换(normal distributions transform, NDT)来计算车辆之间坐标转换关系,并存储RT矩阵。

此外,匹配的两帧点云在具有较大的平移和旋转值时,匹配算法可能需要较长时间才能收敛,甚至无法收敛。因此,本文提出了由粗到精的点云匹配

方法。在粗匹配阶段,利用不同车辆的点云帧进行初步匹配。首先,使用快速点特征直方图(fast point feature histograms, FPFH)算法(Rusu等,2009)从点云中提取关键点和描述符,存储法线的相对方向和位于关键点的球面邻域内的点对之间的距离,再通过随机抽样一致算法(random sample consensus, RANSAC)(Holz等,2015)来估计关键点之间的点

到点关系,得到粗略描述局部地图转换关系的RT矩阵,并以此作为精匹配阶段初始输入。在精匹配阶段,使用ICP算法进一步优化匹配结果,提高匹配精度。同时,计算匹配分数(Holz等,2015)来量化点云匹配的精准程度。匹配分数越小,匹配结果越精确。图4显示了由粗到精匹配算法的有效性,其中ICP匹配、粗匹配、精匹配得分分别为19.6、3.2、1.7E-08。




图4 粗到细匹配的结果

Fig. 4 The result of coarse-to-fine matching ((a) original source; (b) ICP matching; (c) coarse matching; (d) fine matching)

1.4 地图合并

使用无向图 $UCG = \{V, R\}$ 来表示车辆构建点云地图的关系,其中 V 表示车辆节点集, R 表示边集。对于每个节点 $v = \{id, S\} \in V$,它有一个对应的编号 id 和对应的权重 S 。车辆局部地图的累积误差随地图增大而增大,因此以地图的大小作为可信度,即权重 S 。每条边 $r_{ij} \in R$ 表示车辆 i 与车辆 j 的局部地图之间存在一个重合区域。通过GPS可以粗略判断是否存在重合区域,当两者通过地图匹配算法匹配成功时,则认为存在重合区域。为了有效和准确地合并地图,需要优先保留更可靠的局部地图信息。筛选重合区域的相对可信度 Rc ,保留相对可信度大的重合区域,即

$$Rc_{ij} = \frac{Pl_{ij}}{Rl_{ij}} \quad (3)$$

式中, Pl_{ij} 为车辆 i 与车辆 j 重合区域部分的里程数, Rl_{ij} 为车辆 i 起点到重合区域末端的相对里程数。

初始阶段,将用来存储已遍历节点的集合 Se 初始化为空。1)选择集合 $V - Se$ 中权值最小的节点 min ,并寻找节点集 $U \subseteq V - Se$,其每个节点均与 min 节点有边;2)计算 min 和 U 中所有节点对应的重合区域的相对可信度 Rc ,根据 Rc 由大到小进行排序;3)对具有相同 Rc 的重合区域以区域大小为依

据进行由小到大的重新排序;4)按照得到的顺序进行拼图,同时设置 $Se = Se \cup \{min\}$ 。重复步骤1)—4),直到 $Se = V$ 时停止,即获得全局地图。该方法合并过程如图5所示。图5(a)是多个无人车辆对应的局部地图,车辆本身是无序的。随后,它被转换为图5(b)所示的无向图 UCG 。图5(c)—(f)是实现一次循环的过程。图5(g)则是进入下一次循环时的第一步。特别地,这里仅描述了一次循环的过程。

2 基于博弈论的多车调度模型

2.1 构建模型

2.1.1 系统模型

考虑车辆集合 $N = \{1, 2, 3, \dots, N\}$,假设场景中只有一个基站 s ,基站有 M 个信道,则信道集合 $M = \{1, 2, 3, \dots, M\}$ 。每辆车可以在决策周期内选择在本地执行计算任务或将任务通过某一信道卸载至边缘服务器。在每个决策周期内车辆集合不变,但不同决策周期内的车辆集合可能是不相同的。

2.1.2 通信模型

车辆 n 的卸载决策表示为 $a_n \in \{0\} \cup M$,所有




图5 地图合并

Fig. 5 The process of map merging ((a) origin; (b) UCG; (c) step 1; (d) step 2; (e) step 3; (f) step 4; (g) next cycle)

车辆的决策集合 $\mathbf{a} = \{a_1, a_2, \dots, a_N\}$, 其中 $a_n = 0$ 表示车辆 n 在本地执行计算任务, 而 $a_n > 0$ 则表示车辆 n 通过信道 a_n 将任务卸载至边缘。当 $a_n > 0$ 时, 根据所有车辆的决策集合, 可以计算出车辆 n 通过信道 a_n 将任务进行卸载时所能获得的上行速率为

$$r_n(\mathbf{a}) = W \cdot \log_2 \left(1 + \frac{q_n g_{n,s}}{\omega + \sum_{i \in N \setminus \{n\}; a_i = a_n} q_i g_{i,s}} \right) \quad (4)$$

式中, W 是信道带宽, q_n 是车辆 n 的传输能量, $g_{n,s}$ 是车辆 n 和基站 s 间的信道增益, ω 是背景噪声能量, “ $i \in N \setminus \{n\}; a_i = a_n$ ” 表示 i 属于 N (n 除外) 的前提下, $a_i = a_n$ 。目前本文只考虑无线干扰模型下的计算卸载问题。在该情况下, 采用码分多址 (code division multiple access, CDMA) 信道访问方案即可允许多个车辆同时高效地共享同一频段资源。由式(4)可以看出, 如果过多车辆选择同一信道将产生严重干扰, 导致传输速率降低。

2.1.3 计算模型

在决策周期内, 车辆 n 的计算任务 $\mathbf{K}_n = (b_n, d_n)$, 其中 b_n 表示输入数据的大小, d_n 表示完成任务 $\mathbf{K}_n$ 需要的中央处理单元 (central process unit, CPU) 周期总数。每个任务有两种可选计算模式:

1) 本地计算。当车辆 n 进行本地计算时, 仅考虑延迟的影响, 则其开销 C_n^l 由任务的执行时间 T_n^l 组成。设 f_n^m (CPU 周期/s) 为车辆 n 的计算能力, 且

每个车辆的计算能力可以不同。则车辆 n 完成任务 $\mathbf{K}_n$ 的时间为

$$T_n^l = \frac{d_n}{f_n^m} \quad (5)$$

因此对本地计算来说, 总开销为

$$C_n^l = T_n^l \quad (6)$$

2) 卸载计算。当车辆 n 选择通过信道 a_n 将任务进行卸载时, 其开销 $C_n^e(\mathbf{a})$ 由任务的执行时间 $T_n^e(\mathbf{a})$ 和传输时间 $T_n^r(\mathbf{a})$ 两个部分组成。设边缘服务器的计算能力为 f_n^e , 卸载的车辆均分其计算资源。则车辆 n 将任务 $\mathbf{K}_n$ 卸载到边缘时所需要的任务执行时间为

$$T_n^e(\mathbf{a}) = \frac{\sum_{i \in N} I_{|a_i| > 0} d_n}{f_n^e} \quad (7)$$

式中, 指示函数 $I_{|A|}$ 用来表示事件 A 的真假, 事件 A 为真时, $I_{|A|} = 1$; 反之, $I_{|A|} = 0$ 。

车辆 n 将任务 $\mathbf{K}_n$ 卸载时所需要的传输时间为

$$T_n^r(\mathbf{a}) = \frac{b_n}{r_n(\mathbf{a})} \quad (8)$$

因此对卸载计算来说, 总开销为

$$C_n^e(\mathbf{a}) = T_n^e(\mathbf{a}) + T_n^r(\mathbf{a}) \quad (9)$$

2.1.4 问题建模

设 a_n 为车辆 n 的卸载决策, a_{-n} 为其他车辆的卸载决策。则最小开销问题可以被建模为策略博弈

$\Gamma = (N, \{A_n\}_{n \in N}, \{Z_n\}_{n \in N})$, 车辆集合 N 为参与者集, A_n 为车辆 n 的策略集, 开销函数 $Z_n(a_n, a_{-n})$ 表示车辆 n 的成本函数, $\{Z_n\}_{n \in N}$ 为车辆 n 的开销函数, 因此最小开销问题被建模为

$$\min_{a_n \in \{0\} \cup A_n \triangleq \{0, 1, \dots, M\}} Z_n(a_n, a_{-n}) \quad \forall n \in N \quad (10)$$

同时根据式(6)和式(9)可得

$$Z_n(a_n, a_{-n}) = \begin{cases} C_n^l & a_n = 0 \\ C_n^e(a) & a_n > 0 \end{cases} \quad (11)$$

引入纳什均衡的定义:

定义 1 如果所有玩家的决策集合 $\mathbf{a}^* = (a_1^*, \dots, a_N^*)$ 达到纳什均衡, 没有用户有动机改变策略, 即

$$Z_n(a_n^*, a_{-n}^*) \leq Z_n(a_n, a_{-n}^*) \quad \forall a_n \in A_n, n \in N \quad (12)$$

根据纳什均衡的定义, 当最小开销问题存在纳什均衡时, 可以获得次优解。为了证明最小开销问题存在纳什均衡, 引入势博弈的概念, 如定义 2 所示。势博弈的特性之一是至少有一个纳什均衡且具有有限的改进特性。

定义 2 一个博弈被称为势博弈, 则其有势函数 $P(\mathbf{a})$ 对每个 $n \in N$, $a_{-n} \in \prod_{i \neq n} A_i$, a'_n 和 a_n 都属于 A_n , 如果满足

$$Z_n(a'_n, a_{-n}) < Z_n(a_n, a_{-n}) \quad (13)$$

则有

$$P(a'_n, a_{-n}) < P(a_n, a_{-n}) \quad (14)$$

为了证明最小开销问题是势博弈, 构造基于阈值的卸载函数, 函数包括延迟约束和信号质量约束, 定义如下:

1) 延迟约束。为了最小化延迟, 仅当边缘计算的开销小于本地计算的开销时, 用户 n 才进行卸载, 即

$$T_n^e(\mathbf{a}) + T_n^r(\mathbf{a}) < T_n^l \quad (15)$$

2) 信号质量约束。为了保证接收信号质量, 干扰噪声能量不能大于用户 n 的信号能量, 即

$$\omega + \sum_{i \in N \setminus \{n\}: a_i = a_n} q_i g_{i,s} < q_n g_{n,s} \quad (16)$$

此外, 定义 $C = \varepsilon_1 T_n^l + \varepsilon_2 q_n g_{n,s}$ 为计算卸载的阈值, 当车辆 n 的阈值 C_n 小于 C 时, 则进行任务卸载; 反之, 则选择本地计算。阈值函数为

$$C_n = \varepsilon_1 (T_n^e(\mathbf{a}) + T_n^r(\mathbf{a})) +$$

$$\varepsilon_2 (\omega + \sum_{i \in N \setminus \{n\}: a_i = a_n} q_i g_{i,s}) \quad (17)$$

式中, $0 \leq \varepsilon_1, \varepsilon_2 \leq 1$ 分别为两种约束下对应的权重且 $\varepsilon_1 + \varepsilon_2 = 1$ 。

因此构造势函数

$$P(\mathbf{a}) = \frac{1}{2} \sum_{i=1}^N \sum_{n \neq i} C_n C_i I_{\{a_n = a_i\}} I_{\{a_n > 0\}} + \sum_{i=1}^N C_n C_i I_{\{a_n = 0\}} \quad (18)$$

根据定义 2, 要证明最小开销问题是势博弈, 有如下 3 种情况:

1) 假设当前的决策为 $a_k = 0$, 车辆需要将决策从 $a_k = 0$ 更新到 $a'_k > 0$ 。基于 $Z_n(a'_k, a_{-k}) < Z_n(a_k, a_{-k})$, 同时根据卸载的阈值定义有 $\sum_{i \neq k} C_i I_{\{a_i = a'_k\}} < C$, 因此

$$P(a'_k, a_{-k}) - P(a_k, a_{-k}) = \frac{1}{2} C_k \sum_{i \neq k} C_i I_{\{a_i = a'_k\}} + \frac{1}{2} \sum_{k \neq i} C_k C_i I_{\{a'_k = a_i\}} - C_k C < 0 \quad (19)$$

2) 假设当前的决策为 $a_k > 0$, 车辆需要将决策从 $a_k > 0$ 更新到 $a'_k = 0$ 。与情况 1) 类似, 可以得到当 $Z_n(a'_k, a_{-k}) < Z_n(a_k, a_{-k})$ 时, $P(a'_k, a_{-k}) < P(a_k, a_{-k})$ 。

3) 假设当前的决策为 $a_k > 0$, 车辆需要将决策从 $a_k > 0$ 更新到 $a'_k > 0$, 且 $a_k \neq a'_k$ 。因为车辆进行决策更新前后均选择进行卸载, 因此 $\sum_{i \in N} I_{\{a_i > 0\}}$ 不变, 所以有 $T_n^e(\mathbf{a})$ 不变。则 $Z_n(a'_k, a_{-k})$ 和 $Z_n(a_k, a_{-k})$ 的差异仅与信道干扰相关, 同时函数 $W \cdot \log_2(x)$ 随 x 单调递增。所以基于 $Z_n(a'_k, a_{-k}) < Z_n(a_k, a_{-k})$ 有

$$\sum_{i \in N \setminus \{k\}: a_i = a'_k} q_i g_{i,s} < \sum_{i \in N \setminus \{k\}: a_i = a_k} q_i g_{i,s} \quad (20)$$

同时当 $\sum_{i \in N} I_{\{a_i > 0\}}$ 不变时, C_i 与 $\sum_{j \in N \setminus \{i\}: a_j = a_i} q_j g_{j,s}$ 正相关, 因此

$$P(a'_k, a_{-k}) - P(a_k, a_{-k}) = \frac{1}{2} C_k \sum_{i \neq k} C_i I_{\{a_i = a'_k\}} + \frac{1}{2} \sum_{k \neq i} C_k C_i I_{\{a'_k = a_i\}} - \frac{1}{2} C_k \sum_{i \neq k} C_i I_{\{a_i = a_k\}} - \frac{1}{2} \sum_{k \neq i} C_k C_i I_{\{a_k = a_i\}} = C_k (\sum_{i \neq k} C_i I_{\{a_i = a'_k\}} - \sum_{i \neq k} C_i I_{\{a_i = a_k\}}) < 0 \quad (21)$$

综合上述, 最小化开销卸载博弈是势博弈, 得证。

2.2 基于势博弈的卸载算法

基于势博弈的卸载算法流程:

```

initialization
while RTU exists do
    for each  $n \in N$  do
        compute  $C_n$ 
        compute  $b_n(t)$ 
        if  $C_n > C$  then
             $b_n(t) = 0$ 
        if  $b_n(t) \neq a_n(t)$  then
            send RTU
            if receive UD then
                 $a_n(t+1) = b_n(t)$ 
            else
                 $a_n(t+1) = a_n(t)$ 
        else
             $a_n(t+1) = a_n(t)$ 
    end

```

首先,每辆车 n 的卸载决策 $a_n(0)$ 初始化为 0, 当边缘仍能接收到请求更新信息 (request-to-update, RTU) 时,车辆对当前的情况进行决策更新判断。在每个决策时隙 t 中,每辆车计算 C_n 和最佳响应 $b_n(t)$, 若不满足卸载条件则将 $b_n(t)$ 设置为 0。为了加快算法的收敛速度,这里引入 α -Nash 最佳响应动态的概念 (Awerbuch 等, 2008)。因此

$$b_n(t) = \{\tilde{a} : \tilde{a} = \arg \min_{a \in A_n} Z_n(a, a_{-n}(t)) \text{ and } Z_n(\tilde{a}, a_{-n}(t)) \leq (1 - \alpha) Z_n(a_n(t), a_{-n}(t))\}$$

$$0 \leq \alpha \leq 1$$

当获得的 $b_n(t)$ 和当前的决策 $a_n(t)$ 不同时,车辆发送 RTU 以竞争更新决策。在每一时隙中边缘服务器仅选择一辆车发送更新决策信息 (update decision, UD)。收到 UD 的车辆更新自己在下一时隙中的初始决策 $a_n(t+1)$, 未收到的车辆则不进行决策更新。当获得的 $b_n(t)$ 和当前的决策 $a_n(t)$ 相同时,车辆同样不进行决策更新。

2.3 实验仿真

在仿真场景中,基站 s 的覆盖区域设置为 50 m (Quek 等, 2013), 并假定车辆随机地散落在覆盖区域内。其中,基站 s 包括 $M = 5$ 个信道,信道带宽 $W = 5$ MHz,传输能量 $q_n = 0.1$ W,背景噪声 $\omega = -100$ dBm (m 表示绝对值),车辆 n 和基站 s 间的信道增益 $g_{n,s} = l_{n,s}^{-\beta}$ ($l_{n,s}$ 是用户 n 与基站的距离, $\beta = 4$ 是路径损耗因子)。假定每辆车需要调度的任务相同,且计算任务输入数据的大小 $b_n = 5$ MB,运算

需要的 CPU 周期数 $d_n = 3\,000$ MHz。每辆车的计算能力 f_n^m 在 $[0.5, 1]$ GHz 范围内进行随机设置,基站的计算能力为 $f_n^e = 10$ GHz。

本文使用平均时隙数量和平均系统开销作为评估指标,以验证算法的收敛速度和减少系统开销的效率,实验结果如图 6 和图 7 所示。本实验暂不考虑信号能量约束, ε_1 的值被设置为 1。为了寻找一个合适的 α 保证算法效率,实验中 α 分别设置为 0.4, 0.6, 0.8, 1, 在车辆数量 $n = 10, 20, \dots, 50$ 情况下重复实验 100 次。从图 6 可以看出,在不同车辆数量下,随着 α 增大,收敛需要的平均时隙数量增大,即收敛速度降低。图 7 则表示了在不同车辆数量下,较大的 α 下通常得到的平均系统开销更小,即减少系统开销的效率更高。为了在加快收敛速度的情况下保证减少系统开销的效率, α 设置为 0.8。此外,从图 6 和图 7 中可以看出算法具有较快的收敛速度并且能很好地适应多车的不同规模。




图 6 不同车辆数量下收敛所需的平均时隙数量

Fig. 6 Average number of slots for convergence with different number of vehicles




图 7 不同车辆数量下的平均系统开销

Fig. 7 Average system-wide overhead with different number of vehicles

3 实验

3.1 实验设置

实验使用 4 辆硬件配置相同的电动巡逻车和

3 个基站实现道路测试,并与单车建图结果进行对比。

测试场景路段约 1.49 km,包括转弯、直行和变道,如图 8 所示。单车建图时,仅使用本地车载单元进行计算,沿着轨迹 A-B-C-D-E-F-G-H-I-J-K-L-I-H-A-D 进行建图。在多车场景中,由于实际车辆数量有限,以基站为中心将测试区域分为 3 个部分来模拟 9 辆车的 SLAM 效果,分别为 A-B-C-D-A、A-D-E-F-G-H-A、H-I-L-K-J-I-H,并保证每个部分内至少 3 辆车同时运行。每辆车上均安装一台 Velodyne HDL-32 激光雷达扫描仪和一系列惯性测量单元设备。使用搭载 ARM A57 qual-core 的 Tegra X2 和搭载 Intel Xeon Platinum 8168 的服务器分别作为车载单元和边缘服务器。Tegra X2 通过无线网桥与边缘服务器通信,详细的硬件规格列于表 1。为了更快地执行在边缘端,边缘服务器也部署了 SLAM 算法,因此在运行时平台之间只需传输传感器数据。




图 8 现实场景道路

Fig. 8 The realistic path

表 1 实验平台硬件配置

Table 1 Hardware specification of the experiment platform

平台	车辆	边缘
设备	Tegra X2	-
主 CPU	ARM A57 quad-core	Intel Xeon Platinum 8168
架构	Pascal	Skylake
时钟频率/GHz	2.0	2.7
内存类型	LPDDR4	LPDDR4
内存大小/GB	8	8

注:“-”表示无内容。

3.2 性能分析

激光雷达 SLAM 构建的 3 维地图如图 9 所示。其中,图 9(a)为单车 SLAM 构建的 3 维地图,图 9(b)则是基于边缘计算多车协同的建图效果。可以发现,单车建图因为在连续点云帧匹配过程中累积误差,从而导致偏移越来越大;而协同建图各车辆路程相对较短,累积误差相对更小,能够通过边缘服务器,利用地图合并方法快速合成相比于单车更精确的地图,且与真实环境地图更接近。




图 9 激光雷达 SLAM 建立的 3 维地图

Fig. 9 3D map built by LiDAR SLAM
((a) single SLAM; (b) cooperative SLAM)

图 10 展示了协同建图、单车建图以及 RTK 这三者的车辆行驶轨迹。RTK 是由差分全球定位系统(difference global positioning system, DGPS)获得的地理测量轨迹。DGPS 的精度可以在分米以内,所以 RTK 测量的数据可以作为轨迹的真值来评估其他情况下轨迹定位精度。从图 10 中对比发现,单车定位建图性能更差,与 RTK 的偏差更大。其原因是单车车载单元受到计算资源限制,无法及时修正累积误差。而基于边缘计算的多车定位建图与 RTK 的轨迹基本吻合,定位结果误差较小。




图 10 车辆行进轨迹

Fig. 10 Trajectory of vehicles

从图 11 中可以看到更多关于定位误差的细节。相比于协同建图,单车 SLAM 的横、纵向误差波动更明显,且在转弯处更容易出现漂移。这是因为此时点云的特征快速变化,更容易积累里程估计误差。而在 A、H 点处(图 11 中协同建图误差的两大高峰),由于缺少协同建图车辆的相关的转弯轨迹信息,导致协同建图后的轨迹误差也相对较高,甚至高于单车建图。但当有足够多的车辆覆盖弯道信息时,这种误差将会减小。与单车 SLAM 相比,基于边缘计算的多车协同 SLAM 的横向定位和纵向定位的平均精度分别提高了 6.0 倍(从 3.604 m 降低至 0.599 m)和 3.9 倍(从 2.681 m 降低至 0.680 m)。在最坏情况下,其横向精度提高了 1.7 倍(从 23.321 5 m 降低至 13.757 4 m),纵向精度提高了 1.6 倍(从 13.510 3 m 降低至 8.554 6 m)。相比于单车建图,基于边缘计算的协同 SLAM 算法可以获得更好的性能,更准确的建图结果。




图 11 定位误差

Fig. 11 Localization error

((a) latitude error; (b) longitude error)

4 结 论

为了解决多车构建高精度地图与定位问题,提出了一种基于边缘计算的多车协同激光雷达 SLAM 算法。通过将多无人驾驶车辆之间的计算卸载决策

问题建模为多用户计算势博弈问题,设计实现了基于势博弈的卸载算法,在模型具有纳什均衡的基础上实现任务调度。此外,基于相对可信度实现了地图合并,这种方法优先保留了相对可信度高的局部地图以提高整体建图的准确度。实验结果表明,基于博弈论的调度算法可以实现卓越的计算卸载性能。在定位方面,与单车建图结果相比,基于边缘计算卸载的协同 SLAM 算法也更接近 RTK 的实验结果,获得更精准的定位数据。

但是本文方法依然存在以下不足:在线调度策略仅考虑了延迟和信号质量的约束,忽略了能耗的影响。此外,调度策略考虑的是静态场景,缺少对实际场景下车辆的运动预测建模。今后将进一步探索能耗因素和车辆移动性对在线调度策略的影响,完善调度框架结构,使得方法更符合实际,以期得到更好的质量性能。

参考文献 (References)

- Awerbuch B, Azar Y, Epstein A, Mirrokni V S and Skopalik A. 2008. Fast convergence to nearly optimal solutions in potential games// Proceedings of the 9th ACM Conference on Electronic Commerce. Chicago, USA: ACM: 264-273 [DOI: 10. 1145/1386790. 1386832]
- Biber P and Strasser W. 2003. The normal distributions transform: a new approach to laser scan matching//Proceedings of 2003 IEEE/RSJ International Conference on Intelligent Robots and Systems. Las Vegas, USA: IEEE: 2743-2748 [DOI: 10. 1109/IROS. 2003. 1249285]
- Chen X, Jiao L, Li W Z and Fu X M. 2016. Efficient multi-user computation offloading for mobile-edge cloud computing. IEEE/ACM Transactions on Networking, 24(5): 2795-2808 [DOI: 10. 1109/TNET. 2015. 2487344]
- Chen X F, Zhang H G, Wu C, Mao S W, Ji Y S and Bennis M. 2019. Optimized computation offloading performance in virtual edge computing systems via deep reinforcement learning. IEEE Internet of Things Journal, 6(3): 4005-4018 [DOI: 10. 1109/JIOT. 2018. 2876279]
- Cui Y, Song J, Ren K, Li M M, Li Z P, Ren Q M and Zhang Y J. 2017. Software defined cooperative offloading for mobile cloudlets. IEEE/ACM Transactions on Networking, 25(3): 1746-1760 [DOI: 10. 1109/TNET. 2017. 2650964]
- Deng S G, Huang L T, Taheri J and Zomaya A Y. 2015. Computation offloading for service workflow in mobile cloud computing. IEEE Transactions on Parallel and Distributed Systems, 26(12): 3317-3329 [DOI: 10. 1109/TPDS. 2014. 2381640]
- Holz D, Ichim A E, Tombari F, Rusu R B and Behnke S. 2015. Regis-

- tration with the point cloud library: a modular framework for aligning in 3-D. *IEEE Robotics and Automation Magazine*, 22(4): 110-124 [DOI: 10.1109/MRA.2015.2432331]
- Li X L, Yang B W, Xie X H, Li D and Xu L J. 2018. Influence of waveform characteristics on LiDAR ranging accuracy and precision. *Sensors*, 18(4): #1156 [DOI: 10.3390/s18041156]
- Liu Y, Yu H M, Xie S L and Zhang Y. 2019. Deep reinforcement learning for offloading and resource allocation in vehicle edge computing and networks. *IEEE Transactions on Vehicular Technology*, 68(11): 11158-11168 [DOI: 10.1109/TVT.2019.2935450]
- Min M H, Xiao L, Chen Y, Cheng P, Wu D and Zhuang W H. 2019. Learning-based computation offloading for IoT devices with energy harvesting. *IEEE Transactions on Vehicular Technology*, 68(2): 1930-1941 [DOI: 10.1109/TVT.2018.2890685]
- Monderer D and Shapley L S. 1996. Potential games. *Games and Economic Behavior*, 14(1): 124-143 [DOI: 10.1006/game.1996.0044]
- Moubayed A, Shami A, Heidari P, Larabi A and Brunner R. 2020. Edge-enabled V2X service placement for intelligent transportation systems [EB/OL]. [2020-08-15]. <https://arxiv.org/pdf/2001.06288.pdf>
- Qi Q, Wang J Y, Ma Z Y, Sun H F, Cao Y F, Zhang L X and Liao J X. 2019. Knowledge-driven service offloading decision for vehicular edge computing: a deep reinforcement learning approach. *IEEE Transactions on Vehicular Technology*, 68(5): 4192-4203 [DOI: 10.1109/TVT.2019.2894437]
- Quek T Q S, de la Roche G, Güvenç I and Kountouris M. 2013. *Small Cell Networks: Deployment, PHY Techniques, and Resource Management*. Cambridge: Cambridge University Press: 260-279
- Rodrigues T G, Suto K, Nishiyama H, Kato N and Temma K. 2018. Cloudlets activation scheme for scalable mobile edge computing with transmission power control and virtual machine migration. *IEEE Transactions on Computers*, 67(9): 1287-1300 [DOI: 10.1109/TC.2018.2818144]
- Rusinkiewicz S and Levoy M. 2002. Efficient variants of the ICP algorithm//*Proceedings of the 3rd International Conference on 3-D Digital Imaging and Modeling*. Quebec, Canada: IEEE: 145-152 [DOI: 10.1109/IM.2001.924423]
- Rusu R B, Blodow N and Beetz M. 2009. Fast point feature histograms (FPFH) for 3D registration//*Proceedings of 2009 IEEE International Conference on Robotics and Automation*. Kobe, Japan: IEEE: 3212-3217 [DOI: 10.1109/ROBOT.2009.5152473]
- Wang Y P, Lang P, Tian D X, Zhou J S, Duan X T, Cao Y and Zhao D Z. 2020. A game-based computation offloading method in vehicular multiaccess edge computing networks. *IEEE Internet of Things Journal*, 7(6): 4987-4996 [DOI: 10.1109/JIOT.2020.2972061]
- Wei Z L, Zhao B K, Su J S and Lu X C. 2019. Dynamic edge computation offloading for internet of things with energy harvesting: a learning method. *IEEE Internet of Things Journal*, 6(3): 4436-4447 [DOI: 10.1109/JIOT.2018.2882783]
- Yang L, Cao J N, Wang Z Y and Wu W G. 2017. Network aware multi-user computation partitioning in mobile edge clouds//*Proceedings of the 46th International Conference on Parallel Processing*. Bristol, UK: IEEE: 302-311 [DOI: 10.1109/ICPP.2017.39]
- Yang L C, Zhang H L, Li X, Ji H and Leung V C M. 2018. A distributed computation offloading strategy in small-cell networks integrated with mobile edge computing. *IEEE/ACM Transactions on Networking*, 26(6): 2762-2773 [DOI: 10.1109/TNET.2018.2876941]
- Zhang J and Singh S. 2014. LOAM: Lidar odometry and mapping in real-time//*Proceedings of Robotics: Science and Systems X*. Berkeley, USA: IEEE: 109-111 [DOI: 10.15607/RSS.2014.X.00]
- Zhang K, Zhu Y X, Leng S P, He Y J, Maharjan S and Zhang Y. 2019. Deep learning empowered task offloading for mobile edge computing in urban informatics. *IEEE Internet of Things Journal*, 6(5): 7635-7647 [DOI: 10.1109/JIOT.2019.2903191]
- Zhe X Y, Li B Y, Zhang X Y, Chen L and Huang K. 2018. Online co-operative 3D mapping for autonomous driving//*2018 IEEE Intelligent Vehicles Symposium*. Changshu, China: IEEE: 256-261 [DOI: 10.1109/IVS.2018.8500615]

作者简介



崔明月, 1992年生, 男, 博士研究生, 主要研究方向为智能机器人与边缘计算。

E-mail: cuimy@mail2.sysu.edu.cn



黄凯, 通信作者, 男, 教授, 主要研究方向为无人系统与智能机器人。

E-mail: huangk36@mail.sysu.edu.cn

钟仕鹏, 男, 硕士研究生, 主要研究方向为自动驾驶、SLAM、边缘计算。E-mail: zhongshp5@mail2.sysu.edu.cn

刘思瑶, 女, 本科生, 主要研究方向为边缘计算。

E-mail: liusy55@mail2.sysu.edu.cn

李博洋, 男, 博士研究生, 主要研究方向为事件脉冲相机以及协同定位与建图技术。E-mail: liby3@mail2.sysu.edu.cn

吴成昊, 男, 本科生, 主要研究方向为3维重建、3维理解。

E-mail: wuchh9@mail2.sysu.edu.cn